Однородность выборок

Не в совокупности ищи единства, но более — в единообразии разделения.

Козьма Прутков

Гипотеза однородности



<u>Данные</u>. Два набора наблюдений x_1, \ldots, x_n и y_1, \ldots, y_m будем рассматривать как реализовавшиеся значения случайных величин X_1, \ldots, X_n и Y_1, \ldots, Y_m .

На протяжении всего изложения будем считать выполняющимися

<u>Допущения</u>

- $\mathbf{\Pi}\mathbf{1}.\ X_1,\ldots,X_n$ независимы и имеют общую ф. р. F(x).
- $\mathbf{\Pi 2}.\ Y_1, \ldots, Y_m$ независимы и имеют общую ф. р. G(x).
- Д3. Обе функции F и G неизвестны, но принадлежат множеству всех непрерывных функций распределения Ω_c .

Нас будет интересовать

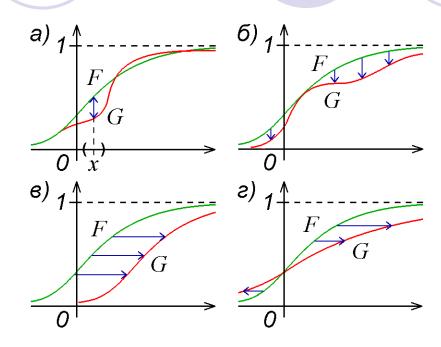
Гипотеза однородности

$$H_0$$
: $G(x) = F(x)$ при всех x .



Альтернативы однородности







- а) $neo\partial nopo\partial nocmu\ H_1:\ G(x) \neq F(x)$ при некотором x (а в силу непрерывности и в некоторой окрестности x);
- б) доминирования H_2 : $G(x) \leq F(x)$ при всех x, причем хотя бы для одного x неравенство строгое;
- в) правого сдвига H_3 : $G(x) = F(x \theta)$, где параметр $\theta > 0$ (эта альтернатива частный случай предыдущей);
 - г) масштаба H_4 : $G(x) = F(x/\theta)$, где $0 < \theta \neq 1$.

Причины рассмотрения альтернатив

- С практической точки зрения бывает важно уловить отклонения от H₀ только определенного вида, скажем, наличие систематического прироста у элементов второй выборки относительно элементов первой выборки
- За счет сужения по сравнению с альтернативой неоднородности H₁ множества распределений, составляющих альтернативное подмножество, удается построить более эффективные (чувствительные) критерии, настроенные на обнаружение отклонений от H₀ конкретного вида

Правильный выбор модели

Две реализации независимых между собой выборок (групп)

При проверке гипотезы однородности двух наборов данных важно понять, с каким из двух случаев мы имеем дело

Парные повторные наблюдения («до» и «после»)



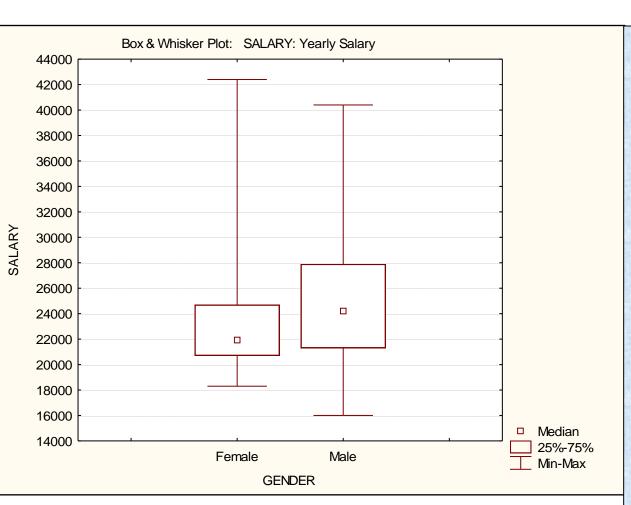






Сравнение зарплат мужчин и женщин





Выдвижение гипотезы

Видим, что в среднем зарплата мужчин немного выше. При этом типичный диапазон её изменения — межквартильный размах — вдвое шире.

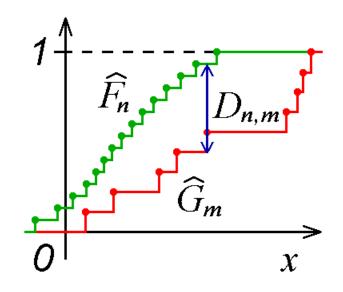
Для выяснения статистической значимости отличия выборок (групп) применяются непараметрические критерии

> Смирнова, Розенблатта, Манна — Уитни.

Критерий Смирнова

Критерий предназначен для обнаружения наиболее общей альтернативы неоднородности H_1 .

Он базируется на величине максимального различия между эмпирическими функциями выборок



$$D_{n,m} = \sup_x \left| \widehat{F}_n(x) - \widehat{G}_m(x) \right|,$$
 где $\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leqslant x\}}, \quad \widehat{G}_m(x) = \frac{1}{m} \sum_{j=1}^m I_{\{Y_j \leqslant x\}},$

т. е. $D_{n,m}$ — расстояние в равномерной метрике между эмпирическими функциями выборок. Слишком большое расстояние противоречит гипотезе H_0 .

Предельная теорема для статистики критерия Смирнова

Предположим, что кроме допущений Д1 - Д3, выполнены ещё два допущения:

- Д4. Все наблюдения $X_1, ..., X_n, Y_1, ..., Y_m$ независимы.
- Д5. Размеры выборок увеличиваются пропорционально: $n / (n + m) \rightarrow \alpha$, $0 \le \alpha \le 1$.

Если верна гипотеза однородности H_0 , то при $n \to \infty$ и $m \to \infty$ имеет место сходимость

$$P\left(\sqrt{nm/(n+m)}D_{n,m}\leqslant x\right)\to K(x).$$

Таким образом, предельным законом для статистики критерия Смирнова служит распределение Колмогорова. Поэтому данный критерий также называют критерием Колмогорова — Смирнова.

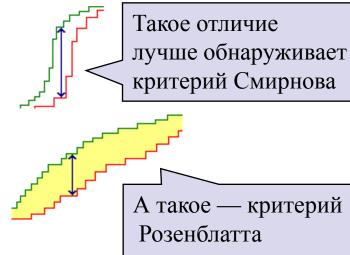
Критерий Розенблатта

Для проверки гипотезы однородности H_0 двух независимых выборок против альтернативы неоднородности H_1 можно воспользоваться также критерием типа ω^2 . Статистика критерия задается формулой

$$\omega_{n,m}^2 = \int_{-\infty}^{\infty} [\widehat{F}_n(x) - \widehat{G}_m(x)]^2 d\widehat{H}_{n+m}(x),$$

где $\widehat{H}_{n+m}(x) = \frac{n}{n+m} \widehat{F}_n(x) + \frac{m}{n+m} \widehat{G}_m(x)$ представляет собой эмпирическую функцию, построенную по объединённой выборке $(X_1, \ldots, X_n, Y_1, \ldots, Y_m)$.

Таким образом, статистика критерия Розенблатта измеряет расхождение между эмпирическими функциями в среднеквадратичном смысле — по существу, на основе величины площади области между эмпирическими функциями.



Ранговая форма статистики критерия Розенблатта

Статистику критерия Розенблатта можно также можно представить в виде

$$\omega_{n,m}^2 = \frac{1}{nm} \left[1/6 + \frac{1}{m} \sum_{i=1}^n (R_i - i)^2 + \frac{1}{n} \sum_{j=1}^m (S_j - j)^2 \right] - 2/3,$$

где R_i — ранг (номер по порядку возрастания значений в объединённой выборке) величины $X_{(i)}$, S_j — ранг величины $Y_{(j)}$.

М. Розенблатт в 1952 г. установил, что при выполнении допущений $\Pi 1-\Pi 5$

$$\mathbf{P}\left(\frac{nm}{n+m}\,\omega_{n,m}^2 \le x\right) \to A_1(x) = 1 - \frac{1}{\pi} \sum_{j=1}^{\infty} (-1)^{j+1} \int_{(2j-1)^2\pi^2}^{4j^2\pi^2} \sqrt{\frac{-\sqrt{y}}{\sin(\sqrt{y})}} \frac{e^{-xy/2}}{y} dy$$

Реализация критерия Розенблатта на языке R

Критерий Розенблатта на языке R реализован функциями cvmts.test и cvmts.pval из пакета CvM2SL2Test (Cramer-von Mises Two Sample Test в метрике L2), вычисляющими, соответственно, статистику критерия и фактический уровень значимости (p-value).

Пакет CvM2SL2Test находится не в Repository (CRAN), а хранится в архиве. Оттуда его можно скачать, зайдя на сайт https://cran.r-project.org/src/contrib/Archive/CvM2SL2Test/ и затем установить кнопкой Install, выбрав в поле ввода Install from: опцию Package Archive File (.zip, .tar.gz).

Для установки пакета CvM2SL2Test под Windows предварительно потребуется установить программу RTools.exe, которую можно скачать с сайта https://cran.r-project.org/bin/windows/Rtools/

Альтернатива критерию Розенблатта

Альтернативой критерию Розенблатта является критерий, предложенный в статье L. Baringhaus and C. Franz (2004) On a new multivariate two-sample test, Journal of Multivariate Analysis, 88, p. 190-206, допускающий обобщение на случай многомерных выборок. Его статистикой служит

$$T_{n,m} = \frac{nm}{n+m} \left[\frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} \left\| X_i - Y_j \right\| - \frac{1}{2n^2} \sum_{i=1}^{n} \sum_{k=1}^{n} \left\| X_i - X_k \right\| - \frac{1}{2m^2} \sum_{j=1}^{m} \sum_{k=1}^{m} \left\| Y_j - Y_k \right\| \right]$$

В одномерном случае $T_{m,n} = \frac{nm}{n+m} \int_{-\infty}^{\infty} (\hat{F}_n(x) - \hat{G}_m(x))^2 dx$. Эта статистика была

предложена X. Крамером ещё в 1928 г. В отличие от критерия Розенблатта данный критерий не является свободным от вида непрерывного закона. Поэтому его p-value приходится вычислять методом bootstrap. На языке R он реализован функцией cramer.test из пакета cramer.

Акт Чтоб

Практическое задание 1

В файле Prefix-ver.txt содержатся логарифмы частот встречаемости (признак LogFrequency) 985 голландских слов с приставкой ver. Также указан семантический класс слов (признак SemanticClass), имеющий две категории: "opaque" — трудные для понимания, несоставные слова; "transparent" — семантически простые, составные слова.

- 1) Импортируйте файл Prefix-ver.txt в Rstudio
- 2) Отберите слова класса "opaque", запишите их логарифмы частот в выборку х. Отберите слова класса "transparent", запишите их логарифмы частот в выборку у
- 3) Постройте гистограммы для выборок х и у
- 4) Постройте графики эмпирических функций распределения выборок x и y на одном рисунке: для второго графика задайте add=TRUE, col=4
- 5) Установите пакет cramer и проверьте однородность выборок критериями Смирнова и Барингхауса Франца

Односторонний критерий Смирнова

Статистикой этого критерия служит

$$D_{n,m}^{+} = \sup_{x} \left(\widehat{F}_n(x) - \widehat{G}_m(x) \right) = \max_{1 \le i \le n} \left\{ \frac{i}{n} - \widehat{G}_m(X_{(i)}) \right\}$$

Теорема. При справедливости гипотезы H_0 и выполнении допущений Д1-Д5 для любого $x \ge 0$

$$P(\sqrt{nm/(n+m)} D_{n,m}^+ \le x) \to 1 - e^{-2x^2}.$$
 (1)

Согласно определению функции Колмогорова для её правого «хвоста» выполняется разложение

$$1 - K(x) = 2(e^{-2x^2} - e^{-8x^2} + e^{-18x^2} - \dots).$$
 (2)

Второй член заключённого в скобки ряда представляет собой четвёртую степень его первого члена. Пренебрегая им и всеми последующими членами, из сравнения формул (1) и (2) видим, что фактический уровень значимости одностороннего критерия Смирнова примерно вдвое меньше, чем у двустороннего.



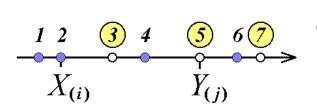
Критерий Манна—Уитни

Критерий Манна — Уитни применяется для проверки гипотезы однородности H_0 против альтернативы доминирования H_2 , в частности, — против альтернативы правого сдвига H_3 .

Вычислим статистику V критерия Манна — Уитни.

- 1) Обозначим через S_j ранг порядковой статистики $Y_{(j)}$ $(j=1,\ldots,m)$ в вариационном ряду, построенном по объединенной выборке $(X_1,\ldots,X_n,Y_1,\ldots,Y_m)$.
 - 2) Положим $V = S_1 + \ldots + S_m$.

Критерий, основанный на V, был предложен Φ . Уилкоксоном в 1945 г. для выборок одинакового размера и распространен на случай $m \neq n$ X. Манном и Д. Уитни в 1947 г.



Суть критерия сводится к следующему: если верна H_0 , то значения $Y_{(j)}$ должны быть рассеяны по всему вариационному ряду; напротив, достаточно большое значение V указывает на тенденцию

преобладания Y_j над X_i , что свидетельствует в пользу справедливости H_2 . Таким образом, критическая область выбирается в виде $\{V > c\}$, где c — некоторая константа.

Основная теоретическая проблема, решённая Манном и Уитни, заключалась в нахождении для заданной границы c соответствующего уровня значимости критерия α_c

Эквивалентные статистики

Несложно установить, что статистика V критерия Манна — Уитни и статистика U, определяемая формулой

$$U = \sum_{i=1}^{n} \sum_{j=1}^{m} I_{\{X_i < Y_j\}},$$

У. Краскел нашел статистику U в работе Г. Дехлера, опубликованной в Германии в 1914 г.

связаны равенством

$$U = V - m(m+1)/2,$$

т. е. они отличаются на известную константу. Поэтому V и U эквивалентны в том смысле, что задают одинаковый критерий.

Аналогичным свойством обладает и статистика разности средних рангов

$$T = \frac{V}{m} - \frac{W}{n},$$

где $W = R_1 + ... + R_n$ — сумма рангов элементов X_i из первой выборки в объединённой выборке (поскольку, очевидно, что V + W = (n+m)(n+m+1)/2.)

Асимптотическая нормальность статистики критерия Манна — Уитни

Предложенная Уилкоксоном ранговая форма статистики критерия V более удобна для вычислений. В свою очередь, с помощью считающей формы U, изученной Манном и Уитни, нетрудно установить, что в случае справедливости гипотезы однородности выборок выполняются следующие равенства:

$$MU = nm/2$$
, $DU = nm(n + m + 1)/12$.

Если гипотеза однородности выборок H_0 верна, то при выполнении допущений $\mathbf{Д1} - \mathbf{Д5}$ имеет место сходимость распределения стандартизированной статистики U^* к стандартному нормальному закону:

$$U^* = (U - \mathbf{M}U)/\sqrt{\mathbf{D}U} \xrightarrow{d} Z \sim \mathcal{N}(0, 1).$$

Для альтернативы доминирования критической 5%-ной границей служит величина 1,645.

Практическое задание 2

- 1) Моделируйте две независимые выборки х и у размера 50:
- а) выборка х должна быть равномерно распределена на отрезке [0, 1]: её функция распределения F(x) = x на [0, 1]
- б) выборка у должна иметь функцию распределения $G(x) = x^3$ на отрезке [0, 1] (используйте метод обратной функции)
- 2) Постройте на одном рисунке разноцветные графики эмпирических функций распределения выборок х и у
- 3) Проверьте выборки на однородность односторонними критериями Смирнова (ks.test) и Манна Уитни (wilcox.test)

Предупреждение! Внимательно изучите описания функций ks.test и wilcox.test, чтобы правильно указать значение аргумента alternative для каждого из критериев.

Модель повторных наблюдений

Для выявления неоднородности реализаций двух <u>зависимых</u> выборок X_1, \ldots, X_n и Y_1, \ldots, Y_n обычно используется следующая модель. Рассматриваются *приращения*

$$Z_i = Y_i - X_i, \quad i = 1, \ldots, n.$$

Каждое из них раскладывается на две части:

$$Z_i = \theta + \varepsilon_i$$

где θ — интересующий нас $\mathfrak{s}\phi\phi\epsilon\kappa m$ воздействия — систематический сдвиг, который мы будем считать положительным, ε_i — случайная ошибка, включающая в себя влияние неучтенных факторов на Z_i .

Предполагается, что выполняется допущение

Сл. в. $\varepsilon_1, \ldots, \varepsilon_n$ — независимы и имеют непрерывные (вообще говоря, разные) распределения такие, что

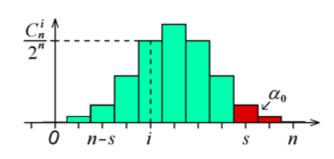
$$\mathbf{P}(\varepsilon_i \leq 0) = \mathbf{P}(\varepsilon_i \geq 0) = 1/2, \quad i = 1, \dots, n.$$

При условии выполнения этого допущения проверяется гипотеза H_0 : $\theta = 0$ против альтернативы H_1 : $\theta > 0$.

Критерий знаков

Критерий знаков предназен для выявления неоднородности реализаций выборок X_1, \ldots, X_n и Y_1, \ldots, Y_n одинакового размера, которые <u>нельзя считать независимыми</u> между собой.

- Зададим уровень значимости малую вероятность α ошибочно отвергнуть верную гипотезу однородности выборок.
 - 2) Положим $Z_i = Y_i X_i$ и $U_i = I_{\{Z_i > 0\}}, i = 1, \ldots, n$.
- 3) В качестве статистики критерия знаков возьмем $S = U_1 + \ldots + U_n$ и подсчитаем ее значение s на реализациях x_1, \ldots, x_n и y_1, \ldots, y_n . (Если значение i-го приращения $z_i = y_i x_i > 0$, то это отмечают знаком "+", если $z_i < 0$ знаком "-". Отсюда происходит название критерия.)



Малые выборки. При $n \leq 15$ вычисляем фактический уровень значимости (p-level)

$$\alpha_0 = \mathbf{P}_0(S \geqslant s) = 2^{-n} \sum_{i=s}^n C_n^i.$$

Если $\alpha_0 \leqslant \alpha$, отвергаем гипотезу H_0 .



Критерий знаковых рангов

Предположим, что приросты имеют вид $Z_i = Y_i - X_i = \theta + \varepsilon_i$ где ε_i — независимые случайные величины, распределение которых непрерывно и симметрично относительно нуля:

$$F(-x) = 1 - F(x)$$
 для всех x .

Тогда для проверки гипотезы

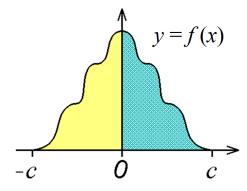
$$H_0$$
: $\theta = 0$

можно применить критерий знаковых рангов, предложенный Уилкоксоном.

Статистикой критерия служит взвешенная сумма

$$T = R_1 U_1 + \dots + R_n U_n,$$

где в качестве *весов* при индикаторах U_i стоят ранги R_i абсолютных величин приростов Z_i .



Плотность f(x) — чётная функция

$$\begin{array}{cccc}
\uparrow & R_i \\
\hline
0 & /Z_i
\end{array}$$

Асимптотическая нормальность статистики критерия знаковых рангов

При выполнении допущений, указанных выше в описании критерия знаковых рангов, справедлива следующая

Теорема. При $n \to \infty$

$$T^* = \frac{T - \mathsf{M}T}{\sqrt{\mathsf{D}T}} = \frac{T - [n(n+1)/4]}{\sqrt{n(n+1)(2n+1)/24}} \overset{d}{ o} Z \sim \mathcal{N}(0,1).$$

Для односторонней альтернативы $\{H_1: \theta > 0\}$ критической границей на уровне значимости 0,05 служит величина 1,645.

Визуальная проверка симметрии распределения

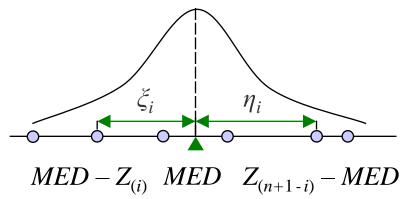


Одним из способов проверки симметрии распределения служит визуальный метод, состоящий в построении диаграммы рассеяния точек с координатами (ξ_i , η_i), где

$$\xi_i = MED - Z_{(i)} \approx \eta_i = Z_{(n+1-i)} - MED, \quad i = 1, \dots, [n/2].$$

Если распределение симметрично относительно медианы, то точки с координатами (ξ_i, η_i) должны располагаться вблизи прямой y = x.

Для проверки симметрии при $n \ge 50$ можно использовать асимптотические критерий Гаствирта, основанный на отличии \overline{X} и MED, или критерий Орлова (см. след. слайд).



Асимптотический критерий Орлова для проверки симметрии

Проверить симметрию распределения относительно 0 можно с помощью **критерия Орлова** (критерий типа омега-квадрат). Статистикой критерия Орлова служит

$$R = \sum_{i=1}^{n} (1 - \hat{F}_n(Z_i) - \hat{F}_n(-Z_i))^2.$$

Видим, что R — сумма квадратов нарушений условия симметрии F(-x)=1-F(x) в точках Z_i , правда не для самой F, а для её оценки \widehat{F}_n .

А. И. Орлов в 1972 г. установил, что при выполнении предположения о симметрии распределение статистики R сходится при $n \to \infty$ к некоторому предельному закону. Приведём три квантили этого закона: $x_{0,9} = 1,2, \, x_{0,95} = 1,66, \, x_{0,99} = 2,8.$

Известны и другие асимптотические критерии проверки симметрии, например,

Hollander M., Wolfe D., Chicken E. Nonparametric Statistical Methods, 3rd Edition, 2013, p. 94.

Практическое задание 3

В файле Pressure.txt приводятся для 15 пациентов данные о систолическом и диастолическом давлении крови непосредственно до принятия и спустя 2 часа после принятия 25 мг каптоприла. Является ли снижение <u>систолического</u> давления статистически значимым?

- 1) Импортируйте файл Pressure.txt и запишите значения признаков СистДо и СистПосл в векторы x и y соответственно
- 2) Вычислите приросты z и постройте для них гистограмму
- 3) Проверьте гипотезу отсутствия эффекта от каптоприла критериями знаков и знаковых рангов Уилкоксона: для 1-го критерия вычислите p-value с помощью функции pbinom, для 2-го критерия используйте функцию wilcox.test
- 4) Постройте диаграмму для проверки симметрии приростов (используйте цикл для подсчёта ξ_i и η_i). Можно ли считать распределение приростов симметричным, т. е. законно ли в данном случае использовать критерий знаковых рангов?

Критерий Стьюдента

Критерий Стьюдента (или t-тест) позволяет проверять гипотезу H_0 о равенстве средних μ_1 и μ_2 двух независимых <u>нормальных</u> выборок:

$$X_i \sim \mathcal{N}(\mu_1, \sigma^2) \ (i = 1, ..., n) \ \text{if} \ Y_j \sim \mathcal{N}(\mu_2, \sigma^2) \ (j = 1, ..., m),$$

где дисперсия σ^2 предполагается одинаковой, но неизвестной.

 $k_1 < k_2$ $y = p_{T_{k_2}}(x)$ сти гипотезы H_0 статистика $T = \sqrt{\frac{nm}{n+m}} \left(\overline{X} - \overline{Y}\right) / S$ имеет распределение Стьюле

Известно, что при справедливо-

$$T = \sqrt{\frac{nm}{n+m}} \left(\overline{X} - \overline{Y} \right) / S$$

x имеет распределение Стьюдента с n+m-2 степенями свободы, обычно обозначаемое как t_{n+m-2} . Здесь

$$S^{2} = \left[\sum_{i=1}^{n} (X_{i} - \overline{X})^{2} + \sum_{j=1}^{m} (Y_{j} - \overline{Y})^{2} \right] / (n + m - 2).$$

Происхождение названия критерия



Распределение Стьюдента t_k впервые появилось в статье Уильяма Д. Госсета (1908), который в то время работал в Дублине на пивоваренном заводе Гиннеса.

Условия контракта не позволяли ему публиковать результаты исследований под собственным именем. Госсет выбрал скромный псевдоним «Student».



Почему не следует применять критерий Стьюдента на практике

- Главным недостатком критерия является допущение о строгой нормальности распределения элементов выборок, которое обычно не выполняется для реальных данных. Для надёжной проверки сложной гипотезы нормальности требуются несколько сотен наблюдений, которых может и не быть в распоряжении исследователя.
- Установлено, что малейшее отклонение распределения от нормального закона приводит к очень быстрому снижению эффективности (чувствительности) критерия Стьюдента (см. следующий слайд).
- Другим условием применимости критерия является равенство дисперсий. Классический F-критерий, предназначенный для проверки этого равенства, весьма чувствителен к утяжелению «хвостов» распределения. Правда, имеются его альтернативы критерии Ливиня и Брауна Форсайта. Однако они основаны на абсолютных отклонениях, поэтому тоже боятся «выбросов».
- Есть ранговые критерии, например, критерий Манна Уитни, которые даже на нормальном законе уступают критерию Стьюдента в эффективности лишь 4,5%, а выиграть могут сколь угодно много на распределениях с тяжёлыми «хвостами».

Неробастность критерия Стьюдента

Робастность (robust (англ.) — крепкий, надёжный, устойчивый) — свойство критерия или оценки, означающее незначительное уменьшение эффективности при малом изменении («возмущении») модели.

Рассмотрим для иллюстрации *модель Тьюки* смеси двух нормальных распределений с математическим ожиданием 0 и стандартными отклонениями 1 и 3 соответственно. Функция распределения $F_{\varepsilon}(x)$ смеси имеет вид $F_{\varepsilon}(x) = (1 - \varepsilon) \Phi(x) + \varepsilon \Phi(x/3)$,

где $\Phi(x)$ — функция распределения $\mathcal{N}(0,1),\ 0\leqslant \varepsilon\leqslant 1.$ Следующая

таблица показывает изменение эффективности $E(F_{\varepsilon})$ в этой модели при небольшом утяжелении «хвостов». Эффективность

ε	0	0,01	0,03	0,05	0,08	0,10	0,15
$E(F_{m{arepsilon}})$	0,955	1,009	1,108	1,196	1,301	1,373	1,497

Эффективность критерия Манна — Уитни относительно критерия Стьюдента

Известно также, что для всех гладких симметричных распределений F

$$E(F) \ge 0.864$$
,

причём эффективность E(F) может быть сколь угодно велика.

Распределение Парето

Говорят, что случайная величина X имеет (стандартное) распределение Парето с параметром $\alpha > 0$, если

shape: 1,5

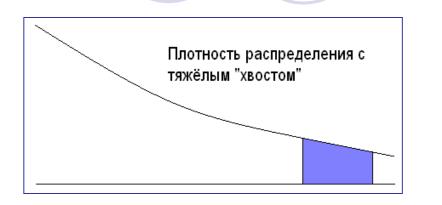
Distribution Function:

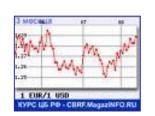
p: ,646447 Density Function:

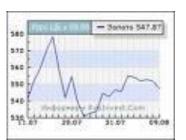
$$P\{X\leqslant x\}=\left\{\begin{array}{ll} 1-x^{-\alpha}, & \text{если } x\geqslant 1,\\ 0, & \text{если } x<1. \end{array}\right.$$

Распределение получило свое название в честь Вилфредо Парето, инженера, ставшего экономистом. Парето получил данное распределение примерно в 1895 году в результате анализа статистических данных о налогах на доход в Англии за 1843 год. Он был поражен тем фактом, что доля индивидуумов, чей доход в два раза превосходил средний, была существенно больше, чем следовало из предположения о нормальности распределения. Изучая данные о доходах во всей Европе в конце 19-го столетия, Парето предложил в качестве приближения для α значение 1,5, которое интерпретировалось им как индикатор заметного неравенства людей в доходах.

Распределения с тяжёлыми «хвостами» в финансовой математике







Б. Мандельброт заметил, что предположение о нормальности распределения цен на хлопок не согласуется с реальными данными. По этой причине он рекомендовал использовать для описания финансового рынка распределения с более тяжелыми «хвостами», чем у нормального закона. В одном из недавних исследований по данному вопросу Э. Ф. Фама, изучая распределения цен акций, использовал закон Парето и получил для параметра α этого закона оценку 1,8.

Преимущества ранговых методов

- Инвариантность относительно формы распределения наблюдений (требуется только непрерывность функции распределения)
- Малая потеря в эффективности (≤ 5%) по сравнению с критериями, опирающимися на предположение о том, что известен (с точностью до параметров) закон распределения наблюдений (обычно — нормальный)
- Хорошая защищённость от «выбросов» (выделяющихся значений) благодаря замене наблюдений на их ранги
- Применимость к малым выборкам (из 5 15 наблюдений)

См. книгу Hollander M., Wolfe D., Chicken E. «Nonparametric Statistical Methods», Third Edition, и сопровождающую её библиотеку NSM3 языка R.

Правильный выбор критерия

Парные повторные наблюдения?

Против альтернативы доминирования?



Односторонние и Манна — Уитни Приросты распределены симметрично?



Критерий знаков

Критерий знаковых рангов





Главное в теме

- 1) Необходимо различать, с чем мы имеем дело: реализациями независимых между собой выборок или парными повторными наблюдениями
- 2) Важно знать, против каких именно альтернатив могут быть использованы те или иные критерии
- 3) Перед вычислением уровней значимости следует построить диаграммы размахов для обнаружения «выбросов» и гистограммы для выявления асимметрии
- 4) Критерий Розенблатта часто оказывается более чувствительным, чем критерий Смирнова, но не всегда
- 5) Критерий знаковых рангов обычно более эффективен, чем критерий знаков, но перед его применением следует проверить симметрию распределения приростов
- 6) Критерий Стьюдента можно использовать только как *вспомогательный инструмент*, на практике его вполне может заменить критерий Манна Уитни



Домашнее задание

- 1) Моделируйте две <u>независимые</u> выборки размера n = 50 из законов N(0,1) и N(0,9) соответственно.
- 2) Проверьте гипотезу однородности выборок критериями Смирнова и Барингхауса — Франца
- 3) Проверьте гипотезу однородности выборок критерием Манна Уитни
- 4) Постройте графики эмпирических функций распределения выборок
- 5) Объясните, почему критерий Манна Уитни не обнаруживает различия распределений выборок